4. PREGUNTAS DE ANÁLISIS CONCEPTUAL Y DISCUSION

4.1. PARTICIÓN DE DATOS Y VALIDACIÓN

Por que es necesario evaluar el modelo en un conjunto de prueba que no haya sido utilizado durante el entrenamiento:
Es fundamental porque queremos saber si el modelo realmente aprendió a predecir con datos nuevos del mundo real. Si lo evaluamos con los mismos datos con los que entrenó, sería como darle a un estudiante el mismo examen con el que estudió. El conjunto de pruebas nos asegura que el modelo no aprendió de memoria.

Que riesgo se corre al reportar únicamente las métricas calculadas sobre el conjunto de entrenamiento:
El riesgo es tener una falsa impresión de que el modelo es muy bueno. Las métricas sobre los datos de entrenamiento siempre van a dar resultados inflados y demasiado optimistas, ocultando fallas reales del modelo.

Cómo se relaciona esto con el dilema sesgo-varianza:
Se relaciona porque un modelo muy complejo puede memorizar todo el ruido de los datos de entrenamiento (alta varianza). Si solo miramos las métricas de entrenamiento, no nos daremos cuenta de que el modelo fallará al recibir datos nuevos.

4.2. DIAGNÓSTICO DE SESGO Y VARIANZA

Análisis del desempeño del modelo:
Al revisar los resultados obtenidos (un valor R2 cercano al 53% tanto en entrenamiento como en prueba), vemos que el rendimiento es casi idéntico en ambas partes, pero la precisión total es moderada.

Diagnóstico de sesgo y varianza:
El modelo sufre de alto sesgo (underfitting).

Justificación:
No hay alta varianza porque el modelo no se sobre adaptó ni memorizó los datos (su rendimiento en prueba no cayó de forma drástica). Sin embargo, una regresión lineal simple usando solo 5 características es demasiado sencilla para capturar todo lo que define el precio de una casa. El modelo es demasiado simple para la complejidad del problema, por lo que su capacidad de predicción se queda corta.